

关系感知类别原型的条件正样本对齐多模态学习方法

0. 论文暂定信息

0.1 中文题目

关系感知类别原型的条件正样本对齐多模态学习方法

0.2 英文题目

Relation-Aware Class Prototype based Conditional Positive Alignment for Multimodal Learning

也可以简称为：

CoPA: Conditional Positive Alignment for Multimodal Learning

0.3 核心关键词

- Multimodal Learning
- Conditional Positive Alignment
- Relation-Aware Prototype
- Cross-modal Agreement
- Complementary Information
- Modality Reliability
- Multimodal Sentiment Analysis

1. 论文核心问题

1.1 传统多模态对齐的隐含假设

现有很多多模态对齐方法默认：

$$(x_t, x_v, x_a)$$

来自同一个样本，因此文本、视觉、音频之间天然构成可靠正样本关系，应该被拉近或对齐。

其中：

- x_t ：文本模态输入；
- x_v ：视觉模态输入；
- x_a ：音频模态输入。

传统方法的潜在逻辑是：

$$\text{paired multimodal samples} \Rightarrow \text{alignment-positive samples}$$

也就是说，只要属于同一个样本，不同模态就应该在共享语义空间中靠近。

1.2 本文反思的核心假设

本文认为：

Paired multimodal samples are not always alignment-positive.

即：

同一样本内的多模态配对，并不总是可靠的可对齐正样本。

在真实多模态任务中，跨模态关系可能有三种情况：

跨模态关系	示例	是否应强制对齐
可靠且一致	文本、语音、表情都表达负面情绪	应该强对齐
可靠但不一致	文本表面积极，但语音低沉、表情疲惫	不应强制对齐，应保留差异
不可靠	音频噪声、视觉遮挡、文本缺失	应降低其训练和融合影响

因此，本文的核心问题不是“如何更强地对齐多模态”，而是：

什么时候应该对齐，什么时候不应该对齐，什么时候应该保留跨模态差异？

2. 论文核心思想

本文提出一种 **条件正样本对齐** 框架。

核心原则是：

先判断跨模态关系，再决定对齐、保留还是抑制。

具体来说：

1. 如果两个模态 **可靠且语义一致**，则将其视为 **agreement-positive**，应该通过类别原型进行对齐；
 2. 如果两个模态 **可靠但语义不一致**，则将其视为 **complementary-positive**，不应强制拉近，而应保留差异；
 3. 如果至少一个模态 **不可靠**，则将其视为 **noisy-positive**，降低其对齐和融合影响。
-

3. 方法整体架构

论文方法由五个部分组成：

编号	模块	作用	是否创新
0	单模态特征编码器	提取文本、视觉、音频表示	否
1	跨模态关系判别模块	判断 agreement / complementary / noisy	是
2	关系感知类别原型构建模块	构造一致性原型和互补性原型	是
3	条件原型对齐与差异保留模块	一致信息对齐，互补信息保留	是
4	融合预测模块	输出分类或回归结果	否

整体流程为：

$x_m \rightarrow h_m \rightarrow (z_m^c, z_m^r) \rightarrow \text{relation identification} \rightarrow \text{relation-aware prototypes} \rightarrow \text{conditional alignment and fusion}$

其中：

$$m \in \{t, v, a\}$$

分别表示文本、视觉、音频。

4. 模块 0：单模态特征编码器

4.1 输入定义

给定一个三模态样本：

$$X^n = \{x_t^n, x_v^n, x_a^n, y^n\}$$

其中：

- x_t^n ：第 n 个样本的文本输入；
- x_v^n ：第 n 个样本的视觉输入；
- x_a^n ：第 n 个样本的音频输入；
- y^n ：样本标签。

对于分类任务：

$$y^n \in \{1, 2, \dots, K\}$$

对于回归任务，可以先将连续情感分数离散化为类别，用于构造类别原型，同时保留回归损失作为主任务损失。

4.2 单模态编码

每个模态通过独立编码器得到单模态特征：

$$h_m^n = E_m(x_m^n)$$

其中：

$$m \in \{t, v, a\}$$

即：

$$h_t^n = E_t(x_t^n)$$

$$h_v^n = E_v(x_v^n)$$

$$h_a^n = E_a(x_a^n)$$

可选实现

如果使用预提取特征：

模态	特征
文本	BERT / RoBERTa embedding
视觉	OpenFace
音频	COVAREP

如果端到端训练：

模态	编码器
文本	Transformer / BERT
视觉	ViT / ResNet / Video Transformer
音频	CNN / Transformer / wav2vec 特征

4.3 公共特征与残差特征分离

对每个模态特征 h_m^n ，使用两个投影头：

$$z_m^{c,n} = P_m^c(h_m^n)$$

$$z_m^{r,n} = P_m^r(h_m^n)$$

其中：

- $z_m^{c,n}$ ：公共语义特征，用于可靠一致关系的对齐；
- $z_m^{r,n}$ ：残差/私有特征，用于可靠不一致关系的差异保留。

通常进行 L2 归一化：

$$z_m^{c,n} \leftarrow \frac{z_m^{c,n}}{\|z_m^{c,n}\|_2}$$

$$z_m^{r,n} \leftarrow \frac{z_m^{r,n}}{\|z_m^{r,n}\|_2}$$

5. 模块 1：跨模态关系判别模块

5.1 单模态预测分布

对每个模态接一个轻量单模态分类头：

$$p_m^n = \text{Softmax}(C_m(z_m^{c,n}))$$

其中：

$$p_m^n \in \mathbb{R}^K$$

表示第 m 个模态对第 n 个样本的类别预测分布。

5.2 模态可靠性估计

使用预测熵估计模态可靠性：

$$H(p_m^n) = - \sum_{k=1}^K p_{m,k}^n \log p_{m,k}^n$$

归一化后定义可靠性：

$$R_m^n = 1 - \frac{H(p_m^n)}{\log K}$$

其中：

$$R_m^n \in [0, 1]$$

含义：

- R_m^n 越接近 1，说明该模态预测越确定，可靠性越高；
 - R_m^n 越接近 0，说明该模态预测越混乱，可能受噪声、缺失或弱语义影响。
-

5.3 跨模态语义一致性估计

对于任意两个模态 i, j ，计算预测分布之间的 Jensen-Shannon Divergence：

$$\text{JSD}(p_i^n, p_j^n) = \frac{1}{2} \text{KL}(p_i^n \| q^n) + \frac{1}{2} \text{KL}(p_j^n \| q^n)$$

其中：

$$q^n = \frac{1}{2}(p_i^n + p_j^n)$$

然后定义语义一致性：

$$A_{ij}^n = \exp\left(-\frac{\text{JSD}(p_i^n, p_j^n)}{\tau_A}\right)$$

其中：

- τ_A ：温度系数；
- $A_{ij}^n \in [0, 1]$ 。

含义：

- A_{ij}^n 高：两个模态预测分布接近，语义判断一致；
- A_{ij}^n 低：两个模态预测分布差异大，可能存在冲突或互补信息。

5.4 三类跨模态关系权重

5.4.1 Agreement-positive 权重

可靠且一致：

$$g_{ij}^{agr,n} = R_i^n R_j^n A_{ij}^n$$

含义：

两个模态都可靠，并且语义判断一致，因此适合进行强对齐。

5.4.2 Complementary-positive 权重

可靠但不一致：

$$g_{ij}^{comp,n} = R_i^n R_j^n (1 - A_{ij}^n)$$

含义：

两个模态都可靠，但语义判断不一致，因此不应强行对齐，而应保留差异。

5.4.3 Noisy-positive 权重

不可靠关系：

$$g_{ij}^{noise,n} = 1 - R_i^n R_j^n$$

含义：

至少一个模态不可靠，应降低其对齐和融合影响。

5.5 模态级关系权重

对于每个模态 m ，可以将它与其他模态的关系求平均，得到模态级权重：

$$g_m^{agr,n} = \frac{1}{M-1} \sum_{j \neq m} g_{mj}^{agr,n}$$
$$g_m^{comp,n} = \frac{1}{M-1} \sum_{j \neq m} g_{mj}^{comp,n}$$

其中：

$$M = 3$$

表示文本、视觉、音频三种模态。

实际训练时建议：

$$g_m^{agr,n}, g_m^{comp,n}$$

使用 `stop-gradient`，避免模型通过操纵关系权重来逃避损失。

6. 模块 2：关系感知类别原型构建模块

6.1 为什么不用普通样本对齐？

如果直接使用样本级对齐：

$$D(z_i^{c,n}, z_j^{c,n})$$

容易受到单个样本噪声、单模态预测错误和局部偶然关系的影响。

因此，本文使用类别原型作为稳定语义锚点。

6.2 为什么不用普通类别原型？

普通类别原型通常是：

$$P_{m,c} = \frac{1}{N_c} \sum_{n: y_n=c} z_m^n$$

但同一类别内部也可能包含不同跨模态关系：

- 有些样本模态一致；

- 有些样本模态冲突；
- 有些样本某个模态受噪声影响；
- 有些样本存在文本-语音-视觉反差。

如果使用单一类别原型，会把一致信息和互补差异全部平均掉。

因此，本文提出 **关系感知类别原型**。

6.3 两类关系感知类别原型

对每个模态 m 、每个类别 c ，维护两个原型：

$$P_{m,c}^{agr}$$

$$P_{m,c}^{comp}$$

其中：

原型	来源	表示含义
$P_{m,c}^{agr}$	可靠且一致样本	第 m 个模态、第 c 类中可对齐的公共语义中心
$P_{m,c}^{comp}$	可靠但不一致样本	第 m 个模态、第 c 类中应保留的互补差异中心

6.4 Agreement prototype 更新

在一个 mini-batch 中，对类别为 c 的样本，用 $g_m^{agr,n}$ 加权更新：

$$\bar{P}_{m,c}^{agr} = \frac{\sum_{n:y_n=c} g_m^{agr,n} z_m^{c,n}}{\sum_{n:y_n=c} g_m^{agr,n} + \epsilon}$$

然后使用 EMA 更新原型：

$$P_{m,c}^{agr} \leftarrow \text{Norm}(\mu P_{m,c}^{agr} + (1 - \mu) \bar{P}_{m,c}^{agr})$$

其中：

- μ ：EMA 动量系数，建议取 $0.9 \sim 0.99$ ；
- ϵ ：防止除零；
- $\text{Norm}(\cdot)$ ：L2 归一化。

如果当前 batch 中某个类别 c 的 agreement 权重过小：

$$\sum_{n:y_n=c} g_m^{agr,n} < \epsilon$$

则该类别原型本轮不更新。

6.5 Complementary prototype 更新

互补原型使用残差特征 $z_m^{r,n}$ 更新：

$$\bar{P}_{m,c}^{comp} = \frac{\sum_{n:y_n=c} g_m^{comp,n} z_m^{r,n}}{\sum_{n:y_n=c} g_m^{comp,n} + \epsilon}$$

EMA 更新：

$$P_{m,c}^{comp} \leftarrow \text{Norm}(\mu P_{m,c}^{comp} + (1 - \mu) \bar{P}_{m,c}^{comp})$$

注意：

- agreement prototype 使用公共特征 z_m^c ；
- complementary prototype 使用残差特征 z_m^r 。

这样可以避免可靠不一致的信息污染公共对齐空间。

7. 模块 3：条件原型对齐与差异保留

7.1 对可靠一致关系进行原型对齐

可靠一致关系应该进入公共语义空间，并通过类别原型实现稳定对齐。

7.1.1 样本到本模态 agreement prototype 的对齐

使用 prototype contrastive loss：

$$\mathcal{L}_{agr}^{proto} = - \frac{\sum_n \sum_m g_m^{agr,n} \log \frac{\exp(\text{sim}(z_m^{c,n}, P_{m,y_n}^{agr})/\tau)}{\sum_{c=1}^K \exp(\text{sim}(z_m^{c,n}, P_{m,c}^{agr})/\tau)}}{\sum_n \sum_m g_m^{agr,n} + \epsilon}$$

其中：

- $\text{sim}(\cdot, \cdot)$ ：余弦相似度；
- τ ：对比学习温度系数；
- P_{m,y_n}^{agr} ：第 m 个模态中真实类别 y_n 对应的一致性原型。

作用：

可靠一致样本的公共特征应靠近本模态、本类别的 agreement prototype，同时远离其他类别的 agreement prototype。

7.1.2 跨模态 agreement prototype 对齐

对同一类别 c ，不同模态的 agreement prototype 应该对齐：

$$\mathcal{L}_{agr}^{cross} = \sum_{c=1}^K \sum_{i < j} \bar{g}_{ij,c}^{agr} D(P_{i,c}^{agr}, P_{j,c}^{agr})$$

其中：

$$\bar{g}_{ij,c}^{agr} = \frac{1}{N_c} \sum_{n: y_n=c} g_{ij}^{agr,n}$$

距离函数可以使用：

$$D(a, b) = 1 - \cos(a, b)$$

该损失的含义：

如果某类别中两个模态经常表现为可靠且一致，那么这两个模态在该类别上的 agreement prototype 应该靠近。

7.1.3 总 agreement loss

$$\mathcal{L}_{agr} = \mathcal{L}_{agr}^{proto} + \alpha \mathcal{L}_{agr}^{cross}$$

其中：

- α ：控制跨模态原型对齐强度。

7.2 对可靠不一致关系进行差异保留

可靠不一致关系不应被直接当作噪声丢弃，也不应被强行对齐。它可能包含有用的互补信息。

例如：

- 文本表面积极，但语音低沉；
- 表情不明显，但音频情绪强；
- 文本语义与视觉表情存在反差；
- 讽刺和幽默场景中，多模态不一致本身就是判别线索。

7.2.1 残差特征靠近本模态 complementary prototype

使用互补原型对比损失：

$$\mathcal{L}_{comp}^{proto} = - \frac{\sum_n \sum_m g_m^{comp,n} \log \frac{\exp(\text{sim}(z_m^{r,n}, P_{m,y_n}^{comp})/\tau)}{\sum_{c=1}^K \exp(\text{sim}(z_m^{r,n}, P_{m,c}^{comp})/\tau)}}{\sum_n \sum_m g_m^{comp,n} + \epsilon}$$

该损失的作用：

可靠但不一致的信息仍然需要类别结构，而不是随意散开。

它保证：

- 同一类别的互补残差信息聚合；
- 不同类别的互补残差信息分离。

7.2.2 不同模态 complementary prototype 保持间隔

对于可靠但不一致的信息，不同模态的 complementary prototype 不应塌缩到一起。

定义 margin separation loss：

$$\mathcal{L}_{comp}^{sep} = \sum_{c=1}^K \sum_{i < j} \bar{g}_{ij,c}^{comp} \max(0, \delta - D(P_{i,c}^{comp}, P_{j,c}^{comp}))^2$$

其中：

$$\bar{g}_{ij,c}^{comp} = \frac{1}{N_c} \sum_{n: y_n=c} g_{ij}^{comp,n}$$

含义：

- 如果某类别中两个模态经常可靠但不一致；
- 那么它们的 complementary prototype 不应被拉到一起；
- 但也不需要无限推远，只要距离大于 margin δ 。

7.2.3 总 complementary loss

$$\mathcal{L}_{comp} = \mathcal{L}_{comp}^{proto} + \beta \mathcal{L}_{comp}^{sep}$$

其中：

- β ：控制互补原型间隔约束强度。

8. 模块 4：融合预测模块

最终融合公共特征和残差特征：

$$z_f^n = \text{Fusion}(z_t^{c,n}, z_v^{c,n}, z_a^{c,n}, z_t^{r,n}, z_v^{r,n}, z_a^{r,n})$$

8.1 简单实现

直接拼接：

$$z_f^n = [z_t^{c,n}; z_v^{c,n}; z_a^{c,n}; z_t^{r,n}; z_v^{r,n}; z_a^{r,n}]$$

然后：

$$\hat{y}^n = C(z_f^n)$$

8.2 加权融合实现

也可以根据模态可靠性进行加权：

$$w_m^n = \frac{\exp(R_m^n)}{\sum_j \exp(R_j^n)}$$

$$z_f^n = \sum_m w_m^n [z_m^{c,n}; z_m^{r,n}]$$

但为了避免方法过于复杂，初始版本建议使用拼接 + MLP。

9. 总体训练目标

9.1 任务损失

分类任务：

$$\mathcal{L}_{task} = - \sum_n \log p(y_n | z_f^n)$$

回归任务：

$$\mathcal{L}_{task} = \frac{1}{N} \sum_n \|\hat{y}^n - y^n\|_1$$

或：

$$\mathcal{L}_{task} = \frac{1}{N} \sum_n (\hat{y}^n - y^n)^2$$

9.2 可选正交解耦约束

为了防止公共特征和残差特征混杂，可以加入轻量正则：

$$\mathcal{L}_{orth} = \sum_n \sum_m |\cos(z_m^{c,n}, z_m^{r,n})|$$

该项不是核心创新，只是辅助约束。

9.3 总损失

基础版本：

$$\mathcal{L} = \mathcal{L}_{task} + \lambda_1 \mathcal{L}_{agr} + \lambda_2 \mathcal{L}_{comp}$$

增强版本：

$$\mathcal{L} = \mathcal{L}_{task} + \lambda_1 \mathcal{L}_{agr} + \lambda_2 \mathcal{L}_{comp} + \lambda_3 \mathcal{L}_{orth}$$

其中：

- λ_1 ：agreement alignment 权重；
- λ_2 ：complementary preservation 权重；
- λ_3 ：正交约束权重。

10. 训练策略

10.1 Stage 1: Warm-up

前若干 epoch 只训练：

$$\mathcal{L}_{task}$$

以及单模态预测头。

目的：

- 让 p_m 有基本预测能力；
- 让 R_m 和 A_{ij} 不至于完全随机；
- 避免早期错误关系判断污染原型。

建议：

$$5 \sim 10 \text{ epochs}$$

10.2 Stage 2: 原型初始化

使用 warm-up 后的特征，在训练集上初始化：

$$P_{m,c}^{agr}$$

$$P_{m,c}^{comp}$$

具体方法：

$$P_{m,c}^{agr} = \text{Norm} \left(\frac{\sum_{n:y_n=c} g_m^{agr,n} z_m^{c,n}}{\sum_{n:y_n=c} g_m^{agr,n} + \epsilon} \right)$$

$$P_{m,c}^{comp} = \text{Norm} \left(\frac{\sum_{n:y_n=c} g_m^{comp,n} z_m^{r,n}}{\sum_{n:y_n=c} g_m^{comp,n} + \epsilon} \right)$$

10.3 Stage 3：联合训练

每个 mini-batch 执行：

1. 输入三模态数据；
2. 得到 h_m 、 z_m^c 、 z_m^r ；
3. 计算单模态预测 p_m ；
4. 计算可靠性 R_m ；
5. 计算一致性 A_{ij} ；
6. 计算关系权重 g^{agr} 、 g^{comp} 、 g^{noise} ；
7. 使用 EMA 更新 P^{agr} 、 P^{comp} ；
8. 计算 $\mathcal{L}_{task}$ 、 $\mathcal{L}_{agr}$ 、 $\mathcal{L}_{comp}$ ；
9. 反向传播更新网络参数。

注意：

- 原型作为 memory buffer，不通过梯度更新；
- 关系权重 g 建议 stop-gradient；
- EMA 更新时应跳过权重过低的类别；
- batch size 太小时，原型更新可能不稳定，可以使用 queue 或全局 memory bank。

11. 最小可行实现版本

为了先跑通实验，建议先实现最小版本。

11.1 保留模块

最小版本只保留：

1. 跨模态关系判别；
2. agreement prototype；
3. complementary prototype；
4. $\mathcal{L}_{agr}^{proto}$ ；
5. $\mathcal{L}_{comp}^{sep}$ ；
6. 任务预测损失。

11.2 最小版本损失

$$\mathcal{L} = \mathcal{L}_{task} + \lambda_1 \mathcal{L}_{agr}^{proto} + \lambda_2 \mathcal{L}_{comp}^{sep}$$

暂时不加入：

- $\mathcal{L}_{agr}^{cross}$ ；
- $\mathcal{L}_{comp}^{proto}$ ；
- $\mathcal{L}_{ortho}$ 。

跑通后再逐步加入增强项。

12. 实验设计

12.1 主实验数据集

推荐使用：

数据集	模态	任务
CMU-MOSI	文本、视觉、音频	情感分析
CMU-MOSEI	文本、视觉、音频	情感分析
CH-SIMS / CH-SIMS-v2	文本、视觉、音频	中文多模态情感分析

可选补充：

数据集	作用
MUSTARD	多模态讽刺检测，适合验证可靠不一致信息
UR-FUNNY	多模态幽默检测，适合验证跨模态反差信息

12.2 对比方法

基础方法

- Text-only
- Audio-only
- Visual-only
- Early Fusion
- Late Fusion
- Concatenation + MLP

经典多模态方法

- TFN
- LMF
- MuT
- MISA
- Self-MM
- MMIM
- DMD

相关最新方法

- DecAlign

- CaReFlow
- UDML
- ARL

12.3 主性能指标

对于 MOSI / MOSEI:

指标	含义
Acc-2	二分类准确率
Acc-7	七分类准确率
F1	分类 F1
MAE	平均绝对误差
Corr	相关系数

对于 CH-SIMS / CH-SIMS-v2:

指标	含义
Acc-2	二分类准确率
Acc-3	三分类准确率
Acc-5	五分类准确率
F1	分类 F1
MAE	回归误差
Corr	相关系数

13. 关键诊断实验

本文不能只做主性能表，必须证明“paired 不一定 alignment-positive”这个问题真实存在。

13.1 Disagreement 分组实验

根据跨模态 disagreement 将测试样本分成三组：

$$D_{sample}^n = \frac{1}{|\mathcal{P}|} \sum_{i < j} \text{JSD}(p_i^n, p_j^n)$$

其中：

$$\mathcal{P} = \{(t, v), (t, a), (v, a)\}$$

按照 D_{sample} 排序，分成：

分组	含义
Low disagreement	模态语义高度一致
Medium disagreement	模态部分不一致
High disagreement	模态冲突明显

比较不同方法在三组上的表现：

方法	Low	Medium	High
普通融合			
强制样本对齐			
普通类别原型			
本文方法			

预期现象：

- 强制对齐在 Low disagreement 样本上可能有效；
- 强制对齐在 High disagreement 样本上可能伤害性能；
- 本文方法在 Low disagreement 上保持对齐收益，在 High disagreement 上避免错误对齐。

13.2 样本对齐 vs 普通类别原型 vs 关系感知类别原型

对比：

版本	含义
Sample Alignment	直接做样本点对点对齐
Standard Class Prototype	每个类别一个普通原型
Relation-Aware Class Prototype	本文的一致性/互补性双原型

要证明：

关系感知类别原型比样本对齐更稳定，比普通类别原型更能保留跨模态差异。

13.3 可靠不一致是否有用

对比：

版本	含义
Only common feature	只使用公共特征
Only residual feature	只使用残差特征
Common + residual	使用完整融合
w/o complementary prototype	去掉互补原型
Full model	完整方法

预期：

- 在 high-disagreement 样本上，残差信息应有明显贡献；
- 去掉 complementary prototype 后，性能应下降；
- 完整模型在讽刺、幽默或情感反差样本上更强。

14. 消融实验设计

消融版本	去掉内容	目的
Full Model	完整模型	最终效果
w/o Relation Identification	不区分 agreement/comp/noise	验证关系判别重要性
w/o Agreement Prototype	去掉一致性原型	验证可靠一致对齐作用
w/o Complementary Prototype	去掉互补性原型	验证可靠差异保留作用
w/o Comp Separation	去掉互补原型间隔约束	验证差异不塌缩的重要性
w/o Reliability	只用一致性，不用可靠性	验证区分噪声与互补差异的必要性
w/o Agreement	只保留互补分支	验证公共语义对齐必要性
Standard Prototype	用普通类别原型替代关系原型	验证关系感知原型优越性
Sample Alignment	用样本对齐替代原型对齐	验证原型级训练更稳定

15. 噪声鲁棒性实验

15.1 单模态加噪

对每个模态分别加噪：

模态	加噪方式
文本	token mask / word dropout / embedding dropout
视觉	Gaussian noise / frame dropout / feature dropout

模态	加噪方式
音频	Gaussian noise / time masking / feature dropout

如果使用预提取特征，可以简单使用：

$$\tilde{x}_m = x_m + \epsilon$$

$$\epsilon \sim \mathcal{N}(0, \sigma^2 I)$$

噪声强度：

$$\sigma \in \{0.1, 0.3, 0.5, 0.7, 1.0\}$$

15.2 预期分析

当某个模态受噪声影响时：

- 该模态预测熵升高；
- 可靠性 R_m 下降；
- 与该模态相关的 g^{agr} 、 g^{comp} 都应下降；
- g^{noise} 上升；
- 该模态不会严重污染 agreement prototype 或 complementary prototype。

16. 可视化实验

建议至少做四类可视化。

16.1 原型空间可视化

使用 t-SNE / UMAP 展示：

- 普通类别原型；
- agreement prototype；
- complementary prototype。

目标：

agreement prototype 应更跨模态接近，complementary prototype 应保留模态间差异。

16.2 Disagreement 分组可视化

画出 Low / Medium / High disagreement 样本的特征分布。

观察：

- 强制对齐是否使 high-disagreement 样本混乱；
 - 本文方法是否能保持互补差异结构。
-

16.3 关系权重变化可视化

在不同噪声强度下画：

$$g^{agr}, g^{comp}, g^{noise}$$

预期：

- clean 且一致样本： g^{agr} 高；
 - 可靠反差样本： g^{comp} 高；
 - 加噪样本： g^{noise} 高。
-

16.4 案例分析

挑选具体样本：

1. 文本、语音、视觉都一致；
2. 文本和语音/视觉冲突；
3. 某个模态受噪声影响；
4. 讽刺或幽默样本。

展示：

- 单模态预测；
 - R_m ；
 - A_{ij} ；
 - g^{agr} 、 g^{comp} 、 g^{noise} ；
 - 最终预测变化。
-

17. 实现注意事项

17.1 关系权重需要 stop-gradient

如果不 stop-gradient，模型可能通过降低 g^{agr} 或 g^{comp} 来逃避对齐损失。

建议实现：

```
g_agr = g_agr.detach()
g_comp = g_comp.detach()
```

17.2 原型不建议作为可学习参数

建议使用 memory buffer + EMA 更新。

原因：

- 类别原型代表统计中心；
- EMA 更稳定；
- 可避免原型被梯度过度牵引。

17.3 Early training 关系判断不稳定

需要 warm-up。

建议：

- 前 5 到 10 个 epoch 不启用原型损失；
- 只训练主任务和单模态预测；
- warm-up 后再初始化原型。

17.4 Batch size 太小的问题

如果 batch size 太小，某些类别在 batch 中样本不足，原型更新会不稳定。

解决方法：

1. 使用较大 batch size；
2. 使用 memory queue；
3. 多 batch 累积后更新原型；
4. 使用全局训练集周期性刷新原型。

17.5 回归任务如何构造类别原型

对于 MOSI / MOSEI 这类情感回归任务，可以将连续标签离散化。

例如：

$$[-3, -2), [-2, -1), [-1, 0), (0, 1], (1, 2], (2, 3]$$

或者使用原始 Acc-7 的七分类划分。

原型类别使用离散标签，主任务仍可使用回归损失。

18. 论文贡献总结

贡献 1：提出条件正样本对齐问题

本文指出，同一样本内的多模态配对并不总是可靠的可对齐正样本。传统无条件对齐可能在跨模态冲突、弱相关和噪声污染场景中造成错误对齐。

贡献 2：提出跨模态关系三分机制

本文根据模态可靠性和跨模态语义一致性，将配对模态关系划分为：

1. agreement-positive;
2. complementary-positive;
3. noisy-positive。

这使模型能够区分：

- 应该对齐的信息；
 - 应该保留的互补差异；
 - 应该降低影响的噪声信息。
-

贡献 3：提出关系感知类别原型

本文为每个类别、每个模态分别构建：

$$P_{m,c}^{agr}$$
$$P_{m,c}^{comp}$$

分别建模：

- 可对齐公共语义；
- 应保留互补差异。

该设计比样本级对齐更稳定，也比普通类别原型更能保留跨模态关系结构。

贡献 4：提出条件原型对齐与差异保留目标

本文对 agreement-positive 样本进行类别原型对齐，对 complementary-positive 样本进行残差信息结构化保留，对 noisy-positive 样本降低训练影响，从而避免错误对齐，同时保留有判别力的跨模态差异。

19. 一句话总结

本文提出一种关系感知类别原型的条件正样本对齐框架，核心观点是：同一样本内的多模态配对不一定是可对齐正样本。模型应先根据模态可靠性和跨模态语义一致性判断关系，再对可靠一致信息进行原型对齐，对可靠不一致信息进行差异保留，并降低不可靠模态的影响，从而同时避免错误对齐和互补信息损失。